Systematyczny przegląd i porównanie możliwości zbierania danych z wersjonowanych repozytoriów kodu w postaci metryk zmian

Modele i metryki jakości w inżynierii oprogramowania

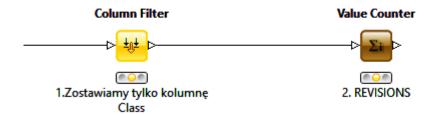
19-12-2013

Bartosz Skuza 179139, Michał Negacz 179120

1 Moser2008

1.1 REVISIONS

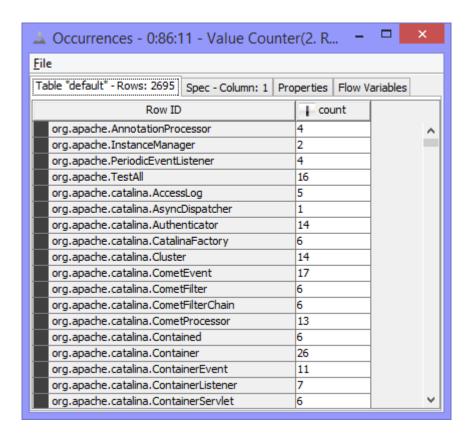
1.1.1 Workflow



1.1.2 **Opis**

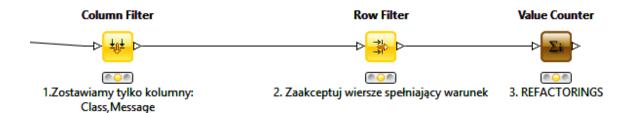
2. Zliczenie po nazwie klasy.

1.1.3 Przykładowe wyniki



1.2 REFACTORINGS

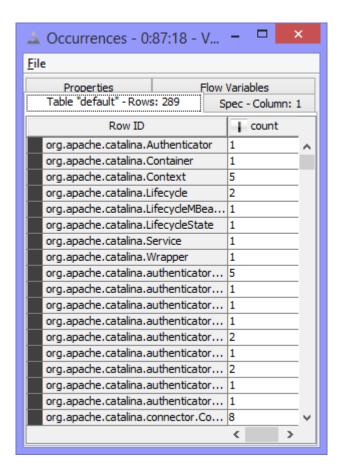
1.2.1 Workflow



1.2.2 **Opis**

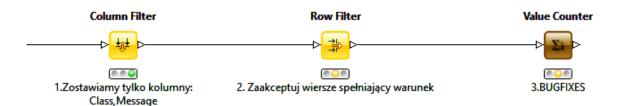
- 2. Zostawienie wierszy , dla których wiadomość zawiera frazę REFACTOR (Wykorzystując wyrażenie regularne " .* refactor.*").
- 3. Zliczenie po nazwie klasy.

1.2.3 Przykładowe wyniki



1.3 BUGFIXES

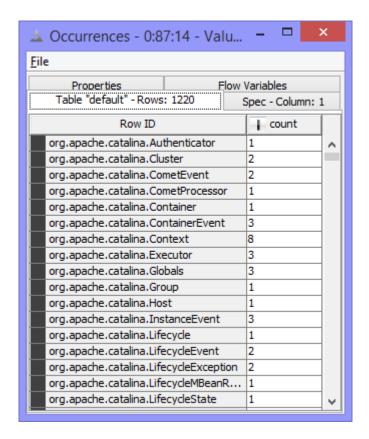
1.3.1 Workflow



1.3.2 Opis

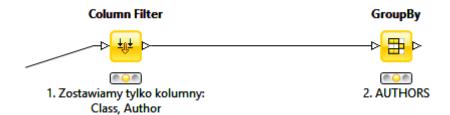
2. Zostawienie wierszy, dla których wiadomość zawiera frazę FIX i nie zawiera fraz PREFIX lub POSTFIX (Wykorzystując wyrażenie regularne " .*([^pre|post]fix).*").

1.3.3 Przykładowe wyniki



1.4 AUTHORS

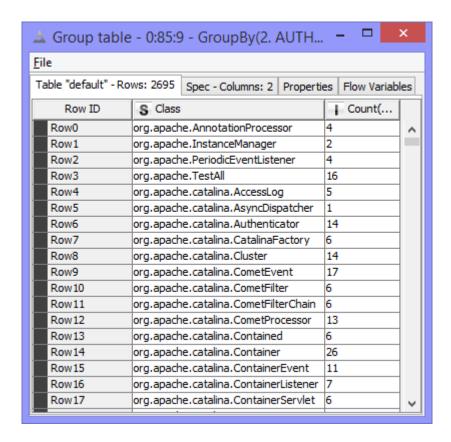
1.4.1 Workflow



1.4.2 Opis

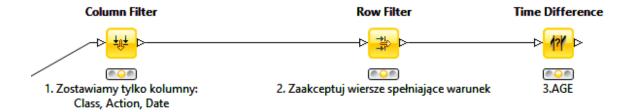
2. Grupowanie po klasie, agregacja zliczanie po autorze.

1.4.3 Przykładowe wyniki



1.5 AGE

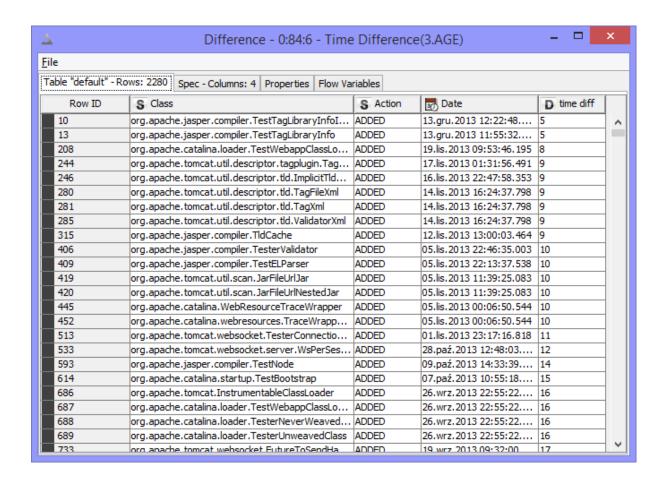
1.5.1 Workflow



1.5.2 **Opis**

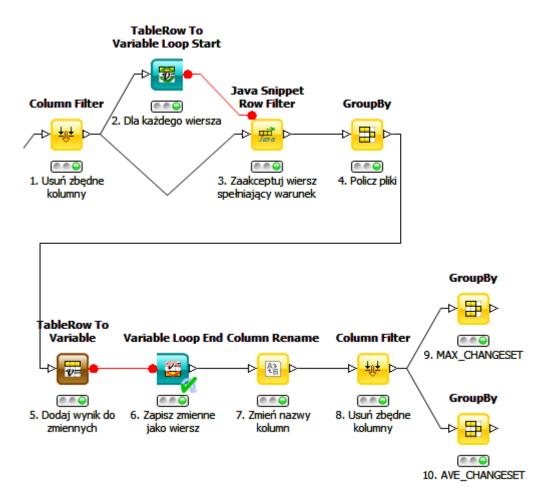
- 2. Zostawienie wierszy, dla których typ akcji ma wartość ADDED.
- 3. Obliczanie różnicy w tygodniach między datą commita a obecną datą.

1.5.3 Przykładowe wyniki



1.6 MAX_CHANGESET, AVE_CHANGESET

1.6.1 Workflow



1.6.2 Opis

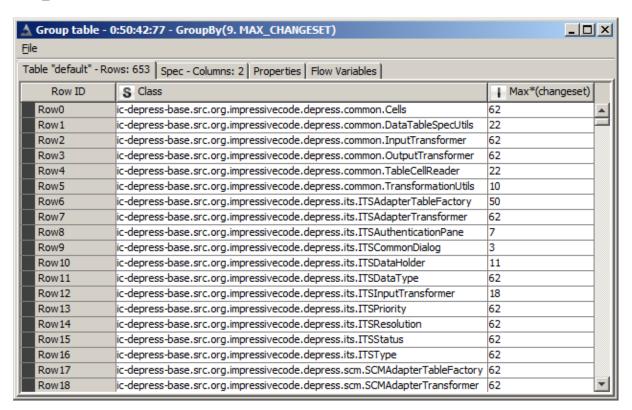
3. Wpisanie kodu akceptującego tylko wiersze, których data jest w przedziale jednej minuty od badanego wiersza. Kod konfiguracyjny węzła:

- 4. Grupowanie po całej tabeli, agregacja zliczanie po nazwie klasy.
- 9. Grupowanie po nazwie klasy, agregacja maksimum po changeset.

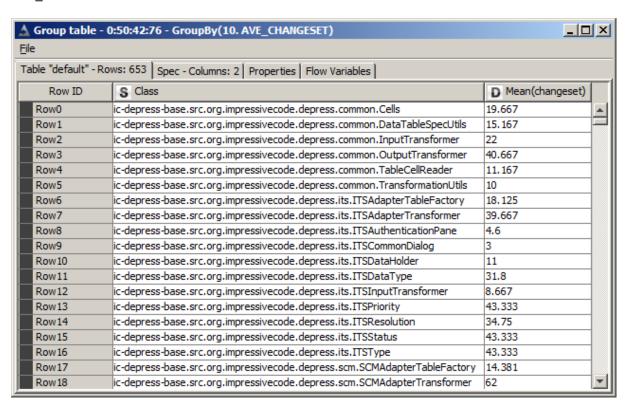
10. Grupowanie po nazwie klasy, agregacja średnia po changeset.

1.6.3 Przykładowe wyniki

MAX_CHANGESET

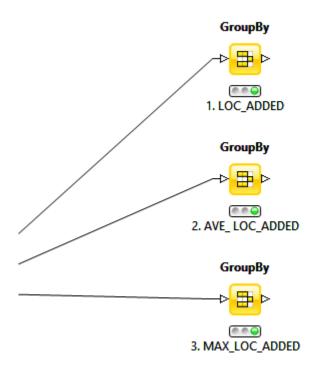


AVE CHANGESET



1.7 LOC_ADDED, MAX_LOC_ADDED, AVE_LOC_ADDED

1.7.1 Workflow

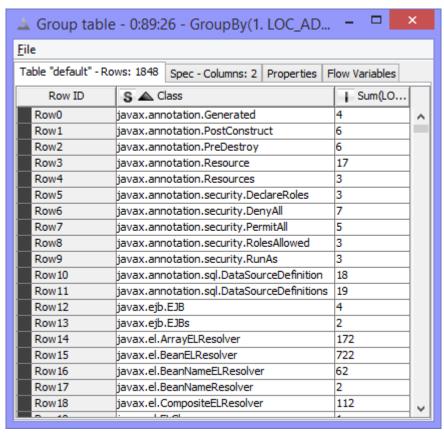


1.7.2 **Opis**

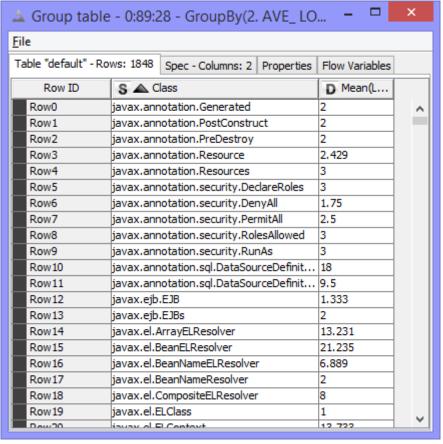
- 1. Grupowanie po klasie, agregacja suma po liniach dodanych.
- 2. Grupowanie po klasie, agregacja średnia po liniach dodanych.
- 3. Grupowanie po klasie, agregacja maksimum po liniach dodanych.

1.7.3 Przykładowe wyniki

1. LOC_ADDED



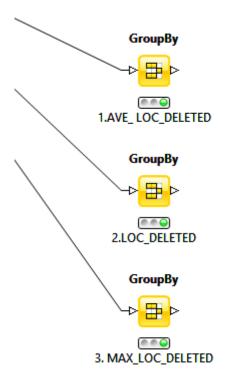
2. AVE_LOC_ADDED



Group tat	ne - 0.69.	27 - GroupBy(3.	. IVIAA	
e				
ble "default" -	Rows: 1848	Spec - Columns: 2	Properties	s Flow Variab
Row ID	S Class	1		→ Max*(L
Row0	javax.anr	javax.annotation.Generated		
Row1	javax.anr	javax.annotation.PostConstruct		
Row2	javax.anr	javax.annotation.PreDestroy		
Row3	javax.anr	javax.annotation.Resource		
Row4	javax.anr	javax.annotation.Resources		
Row5	javax.anr	javax.annotation.security.DeclareRoles		
Row6	javax.anr	javax.annotation.security.DenyAll		
Row7	javax.anr	javax.annotation.security.PermitAll		
Row8	javax.anr	javax.annotation.security.RolesAllo		
Row9	javax.anr	javax.annotation.security.RunAs		
Row10	javax.anr	javax.annotation.sql.DataSourceDefi		
Row11	javax.anr	javax.annotation.sql.DataSourceDefi		
Row12	javax.ejb	javax.ejb.EJB		
Row13	javax.ejb	javax.ejb.EJBs		
Row14	javax.el.	javax.el.ArrayELResolver		
Row15	javax.el.	javax.el.BeanELResolver		
Row16	javax.el.	javax.el.BeanNameELResolver		
Row17	javax.el.	javax.el.BeanNameResolver		

1.8 LOC_DELETED, MAX_LOC_DELETED, AVE_LOC_DELETED

1.8.1 Workflow

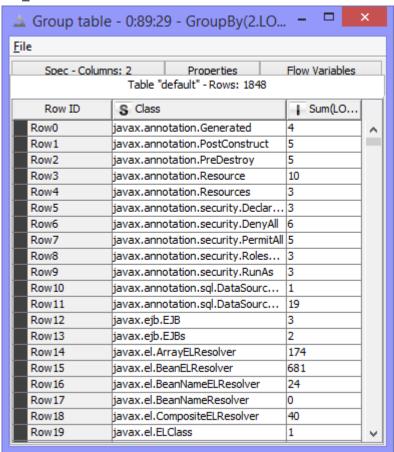


1.8.2 **Opis**

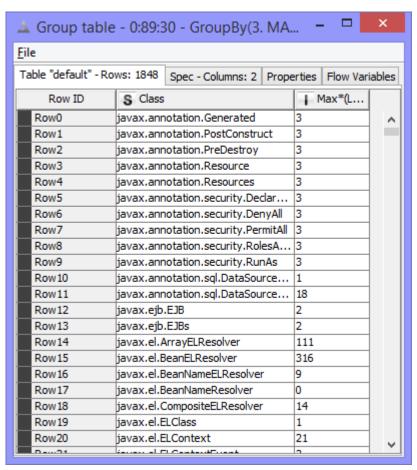
- 1. Grupowanie po klasie, agregacja suma po liniach usuniętych.
- 2. Grupowanie po klasie, agregacja średnia po liniach usuniętych.
- 3. Grupowanie po klasie, agregacja maksimum po liniach usuniętych.

1.8.3 Przykładowe wyniki

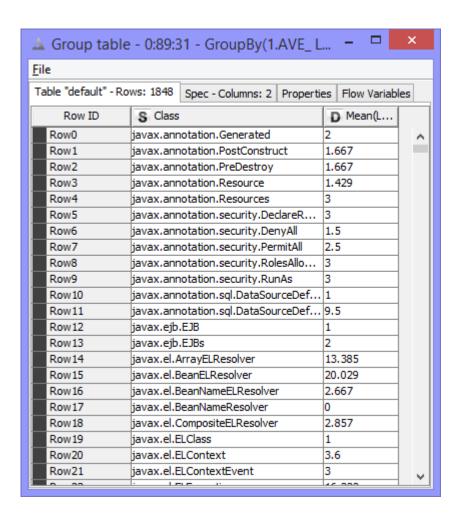
1. LOC_DELETED



2. MAX_LOC_DELETED

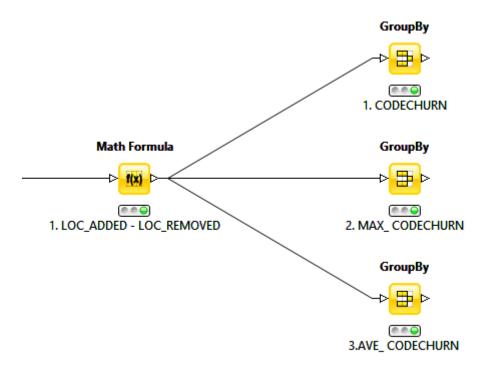


3. AVE_LOC_DELETED



1.9 CODECHURN, MAX_CODECHURN, AVE_CODECHURN

1.9.1 Workflow

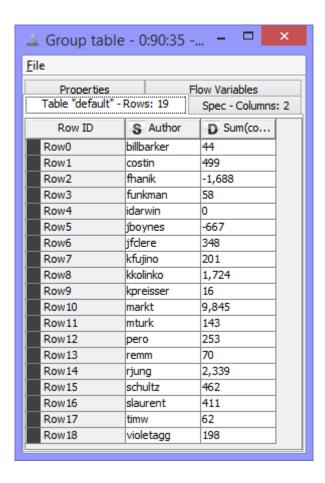


1.9.2 **Opis**

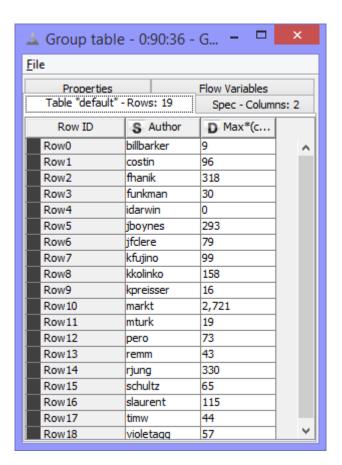
- 1. Policzenie różnicy między liniami dodanymi a liniami usuniętymi.
- 2. Grupowanie po autorze, agregacja suma po codechurn.
- 3. Grupowanie po autorze, agregacja maksimum po codechurn.
- 4. Grupowanie po autorze, agregacja średnia po codechurn.

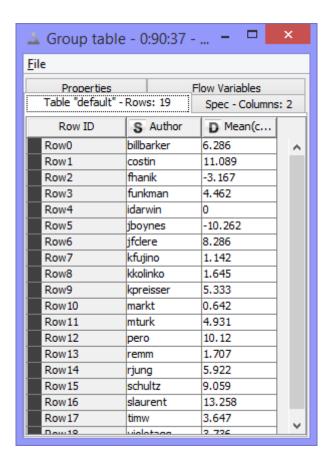
1.9.3 Przykładowe wyniki

1.CODECHURN



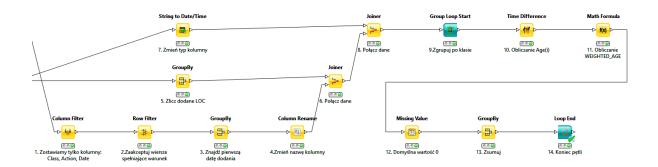
2.MAX_CODECHURN





1.10 WEIGHTED AGE

1.10.1 Workflow



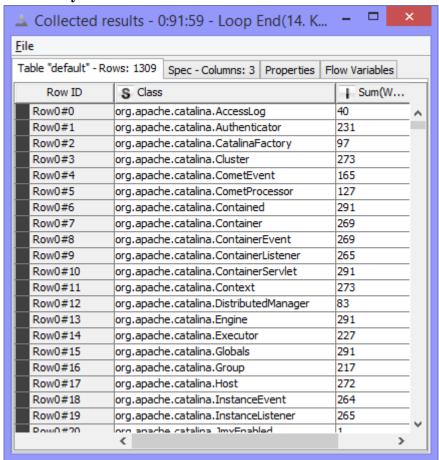
1.10.2 Opis

- 2. Zostawienie wierszy, dla których typ akcji ma wartość ADDED.
- 3. Grupowanie po nazwie klasy, agregacja minimum po dacie.
- 5. Grupowanie po nazwie klasy, agregacja suma po dodanych LOC

- 9. Rozpoczęcie pętli. Grupowanie po nazwie klasy.
- 10. Obliczenie różnicy tygodni pomiędzy pierwszą datą dodania klasy a datą poszczególnych wierszy.
- 11. Wpisanie kodu obliczającego WEIGHTED_AGE:

13. Grupowanie po nazwie klasy i początkowej dacie, agregacja suma po WEIGHTED_AGE.

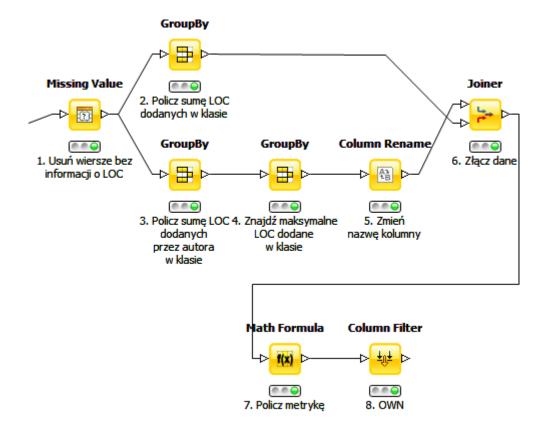
1.10.3 Przykładowe wyniki



2 Rahman 2013

2.1 **OWN**

2.1.1 Workflow

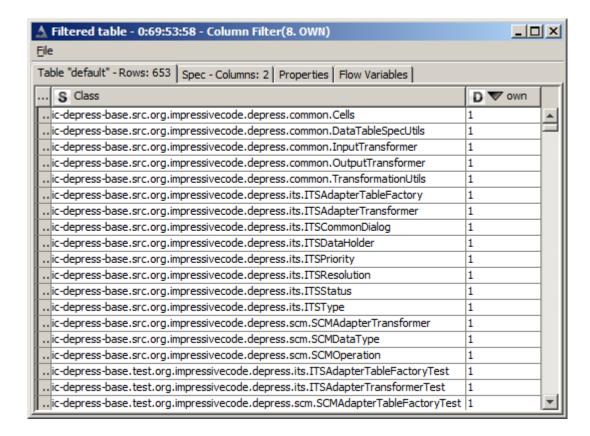


2.1.2 **Opis**

- 2. Grupowanie po nazwie klasy, agregacja suma po dodanych LOC.
- 3. Grupowanie po nazwie klasy i autorze, agregacja suma po dodanych LOC.
- 4. Grupowanie po nazwie klasy, agregacja maksimum sumy dodanych LOC.
- 6. Złączenie Inner join po nazwie klasy.
- 7. Policzenie stosunku maksymalnej LOC przez sumę wszystkich LOC w klasie:

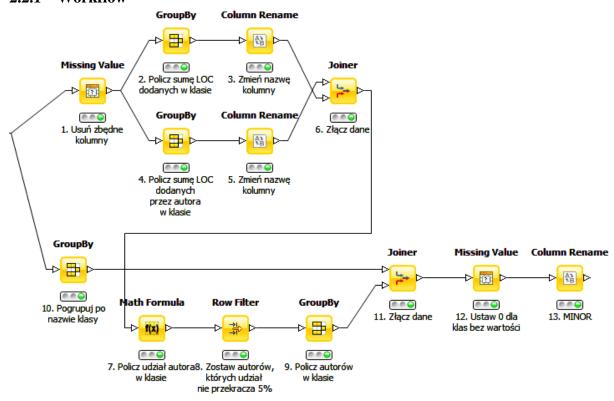
if(\$Sum(loc_added)\$!= 0, \$max_loc_added\$/\$Sum(loc_added)\$, 0)

2.1.3 Przykładowe wyniki



2.2 MINOR

2.2.1 Workflow



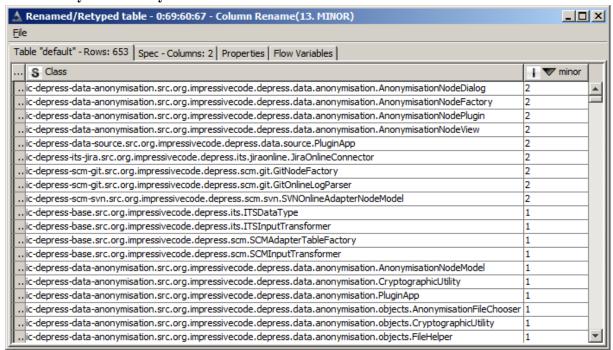
2.2.2 **Opis**

- 2. Grupowanie po nazwie klasy, agregacja suma po dodanych loc.
- 4. Grupowanie po nazwie klasy i autorze, agregacja suma po dodanych loc.
- 6. Złączenie Inner join po nazwie klasy.
- 7. Policzenie stosunku maksymalnej loc przez sumę wszystkich loc w klasie:

\$suma_loc_added_autora\$/\$suma_loc_added\$

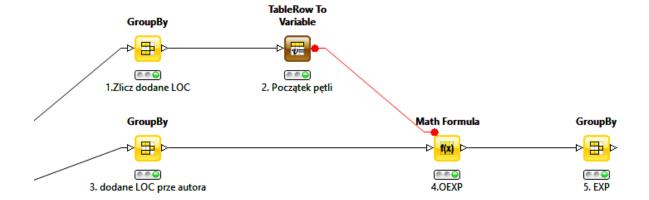
- 8. Filtrowanie po zakresie z górną granicą 0.05.
- 9. Grupowanie po nazwie klasy, agregacja zliczanie po autorze.
- 11. Złączenie Left outer join po nazwie klasy.

2.2.3 Przykładowe wyniki



2.3 OEXP, EXP

2.3.1 Workflow



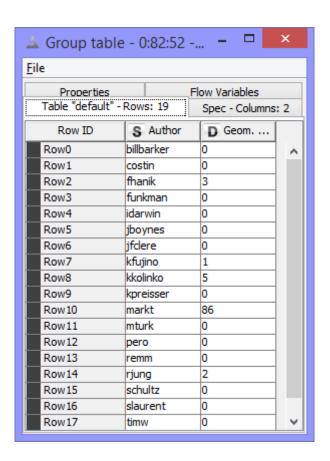
2.3.2 **Opis**

- 1. Agregacja suma po dodanych LOC.
- 3. Grupowanie po nazwie autorze, agregacja suma po dodanych LOC.
- 4. Obliczanie procentu dodanych lini kodu przez poszczególnych autorów do całkowitej liczby dodanych lini kodu.
- 5. Grupowanie po autorze, agregacja średnia geometryczna po OEXP.

2.3.3 Przykładowe wyniki

1.OEXP

e				
Spec - Colu	mns: 3 F	Properties	Flow Variables	;
	Table "defa	ult" - Rows: 19		
Row ID	S Author	Sum(LO	OEXP	I
Row0	billbarker	62	0	1
Row1	costin	1013	0	1
Row2	fhanik	7105	3	1
Row3	funkman	127	0	1
Row4	idarwin	8	0	1
Row5	jboynes	961	0	1
Row6	jfdere	469	0	1
Row7	kfujino	1547	1	1
Row8	kkolinko	11174	5	1
Row9	kpreisser	56	0	1
Row10	markt	190396	86	1
Row11	mturk	383	0	1
Row12	pero	511	0	1
Row13	remm	607	0	1
Row14	rjung	4672	2	1
Row15	schultz	723	0	1

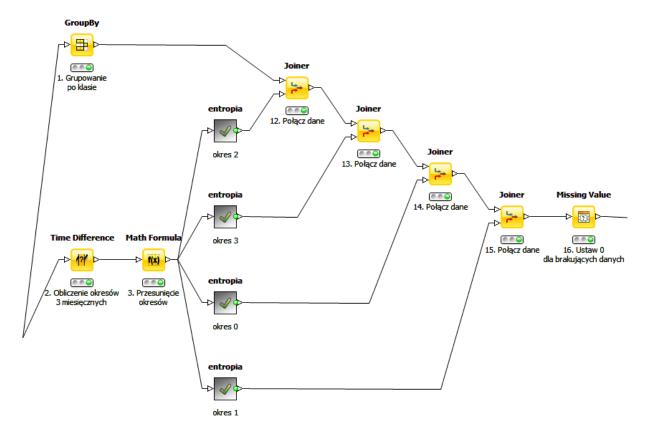


3 Hassan2009

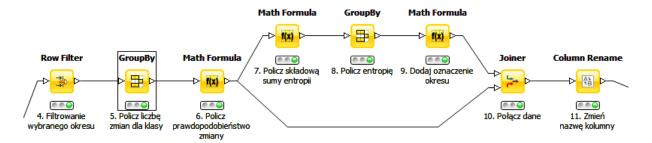
3.1 HCM

3.1.1 Workflow

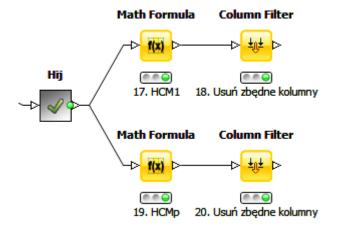
Hij:



Metablok wyliczający entropię:



Dwie wersje metryki:



3.1.2 **Opis**

1. Grupowanie po nazwie klasy, w celu usunięcia duplikatów nazw klas.

- 2. Obliczenie 3 miesięcznych okresów, poprzez różnicę czasu w kwartałach od daty rewizji do daty pierwszej modyfikacji w projekcie.
- 3. Przesunięcie okresów, tak aby najbliższy aktualnej daty miał numer 0, a każdy dalszy o 1 większy. Użyta formuła:
- 3 + \$period\$
- 4. Wybranie zmian wykonanych tylko w wybranym okresie.
- 5. Grupowanie po nazwie klasy, agregacja zliczanie po id commitu, pierwsze wystąpienie numeru okresu.
- 6. Obliczanie prawdopodobieństwa zmiany w okresie:

\$Count(CommitID)\$/COL_SUM(\$Count(CommitID)\$)

- 7. Policzenie składowej sumy entropii:
- \$p\$ * In(\$p\$) / In(\$\$ROWCOUNT\$\$)
- 8. Policzenie entropii dla okresu. Grupowanie po okresie, agregacja suma po składowych entropii.
- 9. Uzupełnienie oznaczenia okresu wpisany na stałe numer okresu.
- 10. Złączenie Inner join po numerze okresu.
- 12-15. Złączenie Left outer join po nazwie klasy.
- 16. Ustawienie stałej wartości 0 dla brakujących danych.
- 17. Policzenie wartości metryki HCM z współczynnikiem c równym 1:

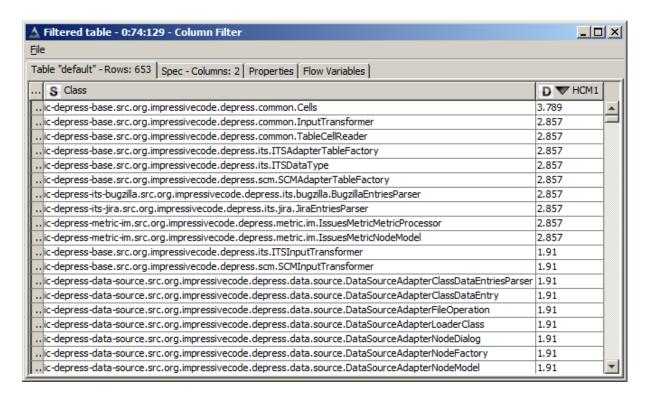
\$entropy_0\$ + \$entropy_1\$ + \$entropy_2\$ + \$entropy_3\$

18. Policzenie wartości metryki HCM z współczynnikiem c równym prawdopodobieństwu zmiany:

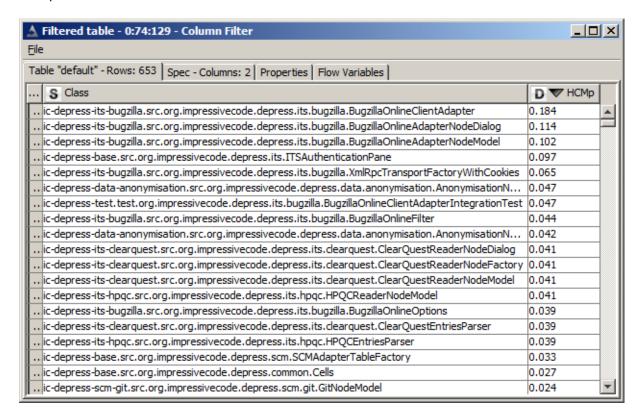
\$p_0\$ * \$entropy_0\$ + \$p_1\$ * \$entropy_1\$ + \$p_2\$ * \$entropy_2\$ + \$p_3\$ * \$entropy_3\$

3.1.3 Przykładowe wyniki

HCM1

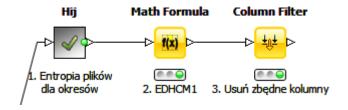


HCMp



3.2 EDHCM

3.2.1 Workflow



3.2.2 Opis

- 1. Obliczenie wartości entropii Hij jak w punkcie 3.1.
- 2. Obliczenie wartość metryki ze współczynnikiem c równym 1 i współczynnikiem opóźnienia równym 1,5:

 $\exp(1.5 * -1) * \exp(0.5 * -2) * \exp(0.5 * -2) * \exp(0.5 * -3) *$

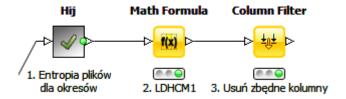
3.2.3 Przykładowe wyniki

ble "default" - Rows: 653 Spec - Columns: 2 Properties Flow Variables		
. S Class	D ▼ EDHCM1	
ic-depress-base.src.org.impressivecode.depress.common.Cells	0.268	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineAdapterNodeDialog	0.255	
. ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineAdapterNodeModel		
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineClientAdapter	0.255	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineFilter	0.255	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.XmlRpcTransportFactoryWithCookies	0.255	
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeDialog	0.255	
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeFactory	0.255	
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeModel	0.255	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeDialog	0.255	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeFactory	0.255	
lic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeModel	0.255	
lic-depress-mg-ipa.src.org.impressivecode.depress.mg.ipa.IssuesMetricTableFactory	0.255	
ic-depress-test. test.org.impressivecode.depress.its.bugzilla.BugzillaOnlineClientAdapterIntegrationTest	0.255	
ic-depress-base.src.org.impressivecode.depress.its.ITSAuthenticationPane	0.208	
ic-depress-base.src.org.impressivecode.depress.its.ITSCommonDialog	0.208	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineOptions	0.208	
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestEntriesParser	0.208	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCEntriesParser	0.208	

4 DAmbros2012

4.1 LDHCM

4.1.1 Workflow



4.1.2 Opis

- 1. Obliczenie wartości entropii Hij jak w punkcie 3.1.
- 2. Obliczenie wartość metryki ze współczynnikiem c równym 1 i współczynnikiem opóźnienia równym 1,5:

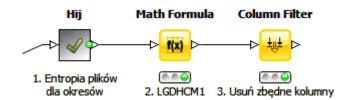
 $(\$entropy_0\$ / (1.5 * 1)) + (\$entropy_1\$ / (1.5 * 2)) + (\$entropy_2\$ / (1.5 * 3)) + (\$entropy_3\$ / (1.5 * 4))$

4.1.3 Przykładowe wyniki

🛦 Filtered table - 0:74:132 - Column Filter(3. Usuń zbędne kolumny)		ı ×
ile		
Table "default" - Rows: 653 Spec - Columns: 2 Properties Flow Variables		
S Class	D ▼ LDHCM1	Γ
ic-depress-base.src.org.impressivecode.depress.common.Cells	1.309	_
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineAdapterNodeDialog	0.937	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineAdapterNodeModel	0.937	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineClientAdapter	0.937	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.BugzillaOnlineFilter	0.937	
ic-depress-its-bugzilla.src.org.impressivecode.depress.its.bugzilla.XmlRpcTransportFactoryWithCookies	0.937	
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeDialog	0.937	1
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeFactory	0.937	1
ic-depress-its-clearquest.src.org.impressivecode.depress.its.clearquest.ClearQuestReaderNodeModel	0.937	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeDialog	0.937	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeFactory	0.937	
ic-depress-its-hpqc.src.org.impressivecode.depress.its.hpqc.HPQCReaderNodeModel	0.937	
ic-depress-mg-ipa.src.org.impressivecode.depress.mg.ipa.IssuesMetricTableFactory	0.937	
ic-depress-test.test.org.impressivecode.depress.its.bugzilla.BugzillaOnlineClientAdapterIntegrationTest	0.937	
ic-depress-base.src.org.impressivecode.depress.common.InputTransformer	0.687	1
ic-depress-base.src.org.impressivecode.depress.common.TableCellReader	0.687	
ic-depress-base.src.org.impressivecode.depress.its.ITSAdapterTableFactory	0.687	
ic-depress-base.src.org.impressivecode.depress.its.ITSDataType	0.687	
., ic-depress-base.src.org.impressivecode.depress.scm.SCMAdapterTableFactory	0.687	

4.2 LGDHCM

4.2.1 Workflow

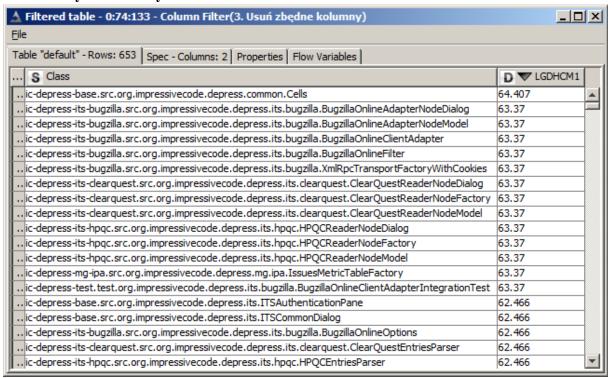


4.2.2 Opis

- 1. Obliczenie wartości entropii Hij jak w punkcie 3.1.
- 2. Obliczenie wartość metryki ze współczynnikiem c równym 1 i współczynnikiem opóźnienia równym 1,5:

 $(\$entropy_0\$ / (1.5 * ln(1.01))) + (\$entropy_1\$ / (1.5 * ln(2.01))) + (\$entropy_2\$ / (1.5 * ln(3.01))) + (\$entropy_3\$ / (1.5 * ln(4.01)))$

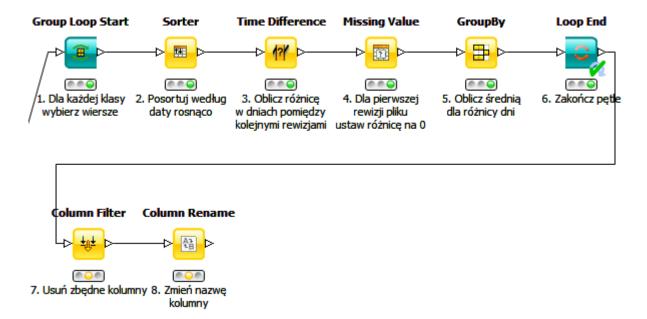
4.2.3 Przykładowe wyniki



5 Tosun2011

5.1 Average Time between Edits

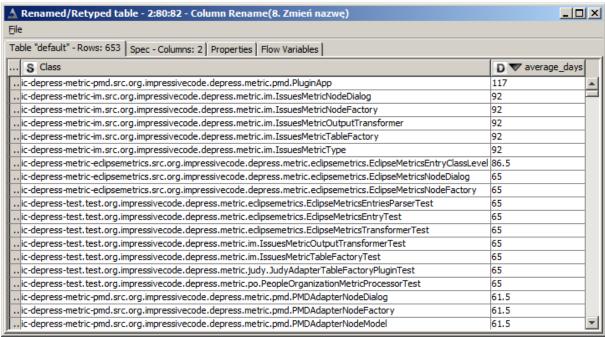
5.1.1 Workflow



5.1.2 Opis

- 1. Grupowanie po nazwie klasy, w celu usunięcia duplikatów nazw klas.
- 2. Sortowanie po dacie rosnąco.
- 3. Różnica w dniach pomiędzy wierszami.
- 5. Grupowanie po nazwie klasy, agregacja średnia po różnicy dni.

5.1.3 Przykładowe wyniki



6 Nagappan2005

Metryki z tej grupy potrzebują uzupełnienia o dodatkowe źródło danych, takie jak informacje z plików źródłowych czy przynależność do plików binarnych.

6.1 Churned LOC / Total LOC

6.1.1 Opis

Oczekujemy, że im większa będzie proporcja liczby linii zmian do liczby wszystkich linii, tym większa gęstość błędów będzie dla tego pliku.

6.2 Deleted LOC / Total LOC

6.2.1 Opis

Oczekujemy, że im większa będzie proporcja liczby linii usuniętych do liczby wszystkich linii, tym większa gęstość błędów będzie dla tego pliku.

6.3 Files churned / File count

6.3.1 Opis

Oczekujemy, że im większa proporcja liczby zmienionych plików do liczby plików, tym większe prawdopodobieństwo, że pliki zmienione wprowadzą defekty. Na pliki binarne A i B składa się po 20 plików. Jeżeli w A było zmieniane 5 plików, a w B 2 pliki to oczekujemy, że A ma większą szansę na wprowadzenie defektów.

6.4 Churn count / Files churned

6.4.1 Opis

Przypuśćmy, że na pliki binarne A i B składa się po 20 plików, z czego dodatkowo po 5 plików było zmienianych. Jeżeli pliki z A były zmienianie 20 razy, a z B 10 razy to oczekujemy, że plik binarny A będzie miał większą gęstość błędów.

6.5 Weeks of churn / File count

6.5.1 Opis

Metryka uwzględnia czasowy zakres zmian. Wyższa jej wartość oznacza, że więcej czasu zajmuje praca nad małą liczbą plików. Może to wskazywać, że plik binarny zawiera złożone pliki, które są trudne w poprawnej pielęgnacji. Oczekujemy, że przy wzroście tej metryki może towarzyszyć wzrost gęstości błędów w pliku binarnym.

6.6 Lines worked on / Weeks of churn

6.6.1 **Opis**

Metryka mierzy zakres zmian w czasie. Liczba tygodni zmian niekoniecznie wskazuje na liczbę zmian. Oczekuje się że im większa liczba linii kodu, nad którymi pracujemy, tym więcej będzie tygodni zmian. Wysoka wartość może oznaczać podwyższoną gęstość błędów.

6.7 Churned LOC / Deleted LOC

6.7.1 Opis

Nie wszystkie zmiany dotyczą naprawy błędów. W przypadku nowych funkcjonalności liczba linii zmian będzie większa niż liczba linii usuniętych. Wysoka wartość tej metryki może wskazywać na wprowadzenie nowej funkcjonalności.

6.8 Lines worked on / Churn count

6.8.1 Opis

Oczekujemy, że im większa liczba linii kodu, nad którymi pracujemy, w stosunku do liczby zmian, tym większa będzie gęstość zmian.

7 Program zapisujący do pliku dodane usunięte LOC z git

```
#!/bin/bash
```